

Análise preditiva em vídeos verticais: uma análise exploratória de dados e aplicação de machine learning sobre métricas de retenção e engajamento nas plataformas TikTok e YouTube Shorts

Vitor Hugo Mondardo Silveira e Rodrigo Ramos Dornel

Bacharelado em Sistemas de Informação

Universidade da Região de Joinville (Univille) Joinville – SC – Brasil

vitor.silveira@univille.br rodrigodornel@univille.br

Abstract. *The advancement of digital platforms has significantly modified marketing strategies, shifting a large part of consumer communication to virtual environments. In this context, vertical-screen content has become fundamental in retaining user attention—now considered a scarce resource—and in directly shaping new consumption behaviors. The objective of this study was to analyze how attention retention in vertical-screen content influences consumption behavior. To this end, the methodology comprised exploratory and quantitative bibliographic research, using real data from TikTok and YouTube Shorts. The methodological procedure relied on a Python-implemented pipeline encompassing data cleaning, feature engineering, Pearson correlation, and four machine learning models (Linear Regression, Ridge, Random Forest, and Gradient Boosting), all evaluated by cross-validation. The results indicate that absolute watch time is the strongest predictor of engagement, presenting a strong and statistically significant correlation, while relative retention demonstrated no relevant association. The Random Forest model independently confirmed this hierarchy, concentrating about 65% of predictive importance on absolute exposure time. In the at-scale database, the apparent correlation between retention and engagement disappeared when stratified by platform, revealing a composition effect that masked the absence of an internal relationship within each ecosystem. Therefore, it is concluded that effective exposure time is the primary indicator of engagement in vertical videos, and that each network must be analyzed independently to optimize strategies.*

Keywords: *Attention retention. Vertical screen. Digital marketing. Engagement. Data analysis. Machine learning.*

Resumo. *O avanço das plataformas digitais modificou significativamente as estratégias de marketing, deslocando grande parte da comunicação com consumidores para ambientes virtuais. Nesse contexto, os conteúdos em tela vertical tornaram-se fundamentais na retenção da atenção dos usuários — hoje considerada um recurso escasso — e na formação direta de novos comportamentos de consumo. O objetivo deste trabalho foi analisar como a retenção de atenção em conteúdos de tela vertical influencia o comportamento de consumo. Para isso, a metodologia compreendeu pesquisa bibliográfica exploratória e quantitativa, utilizando dados reais do TikTok e YouTube Shorts. O procedimento metodológico contou com um pipeline implementado em Python que englobou limpeza de dados, engenharia de atributos, correlação de Pearson e modelos de aprendizado de máquina (Regressão Linear, Ridge, Random Forest e Gradient Boosting), todos avaliados por validação cruzada. Os resultados indicam que o tempo absoluto assistido é o preditor mais forte do engajamento, apresentando correlação forte e estatisticamente significativa, enquanto a retenção relativa não demonstrou associação relevante. O modelo Random Forest confirmou essa hierarquia de forma independente, concentrando cerca de 65% da importância preditiva no tempo de exposição absoluto. Na base de dados em escala, a correlação aparente entre retenção e engajamento desapareceu ao estratificar por plataforma, revelando um efeito de composição que mascarava a ausência de relação interna em cada ecossistema. Conclui-se, portanto, que o tempo efetivo de exposição é o principal indicador de engajamento em vídeos verticais e que cada rede deve ser analisada independentemente para otimizar estratégias.*

Palavras-chave: *Retenção de atenção. Tela vertical. Marketing digital. Engajamento. Análise de dados. Machine learning.*

1. INTRODUÇÃO

O século XXI consolidou uma inversão de lógica no mercado comunicacional: se antes a escassez estava nos produtos e serviços, hoje ela reside na atenção humana. Conforme Simon (1971), a abundância de informação gera escassez de atenção, princípio que fundamenta a economia da atenção. Nesse modelo, a atenção do usuário deixa de ser um efeito do consumo de mídia e passa a constituir um dos principais ativos disputados pelas plataformas digitais (HEITMAYER, 2025). Nesse contexto, o smartphone tornou-se o principal meio de consumo de conteúdo digital. Como os usuários utilizam seus dispositivos predominantemente na posição vertical e grande parte do acesso às redes sociais ocorre por dispositivos móveis (SCIENTIA MOBILE, 2014, NAVARRO-GÜERE, 2023; SLADE-SILOVIC, 2018), o formato vertical consolidou-se como uma nova linguagem audiovisual, rompendo com a predominância histórica do formato horizontal (NAVARRO-GÜERE, 2023; MULIER; SLABBINCK; VERMEIR, 2021). Essa transformação impulsionou plataformas como TikTok e YouTube Shorts, onde vídeos curtos são consumidos continuamente e distribuídos por sistemas algorítmicos de recomendação (MANIC, 2024; YANG et al., 2025). Nesse ambiente, métricas de retenção e engajamento tornaram-se indicadores centrais do interesse dos usuários, especialmente porque o tempo de visualização funciona como um sinal implícito de preferência em sistemas de reprodução automática (YANG et al., 2025). Diante desse cenário, este trabalho teve o objetivo de analisar como a retenção de atenção em conteúdos de tela vertical influencia o comportamento de consumo, utilizando técnicas de análise de dados e aprendizado de máquina para identificar padrões entre duração, retenção e engajamento.

2. REVISÃO DA LITERATURA

Este capítulo apresenta a fundamentação teórica que sustenta o desenvolvimento da pesquisa, abordando conceitos relacionados à economia da atenção, ao consumo de conteúdo digital, aos vídeos curtos em formato vertical e aos indicadores de engajamento utilizados pelas plataformas digitais.

2.1 ECONOMIA DA ATENÇÃO NO AMBIENTE DIGITAL

A noção de atenção como um recurso cognitivo limitado e escasso foi pioneiramente formalizada em 1971: em um mundo saturado de informações, as limitações não são os dados, e sim a capacidade humana de processá-los. Portanto, uma abundância de informação cria uma pobreza de atenção (SIMON, 1971). A economia da atenção é definida como uma abordagem de gestão da informação que trata a atenção humana como um recurso escasso e aplica a teoria econômica para resolver problemas de gestão da informação (DAVENPORT, BECK, 2001).

2.2 FORMATO VERTICAL E LINGUAGEM AUDIOVISUAL MOBILE

A consolidação do vídeo vertical está associada à ergonomia dos smartphones, já que os usuários utilizam predominantemente os dispositivos na posição vertical, tornando o consumo de conteúdo mais natural e fluido (NAVARRO-GÜERE, 2023). Com a popularização de plataformas como TikTok e YouTube Shorts, o formato deixou de ser apenas uma adaptação técnica e passou a constituir uma linguagem nativa das mídias móveis (NAVARRO-GÜERE, 2023). Além disso, vídeos verticais apresentam maior fluência cognitiva em dispositivos móveis, exigindo menor esforço de processamento e despertando maior interesse dos consumidores (MULIER; SLABBINCK; VERMEIR, 2021). Nesse contexto, plataformas como o TikTok passaram a ocupar papel estratégico no marketing digital, especialmente por meio de vídeos curtos capazes de influenciar a intenção de compra de consumidores da Geração Z (VALEZA; SORIANO, 2024).

2.3 RETENÇÃO DE ATENÇÃO

Nas mídias sociais, a atenção tornou-se um recurso central da economia digital, funcionando como uma moeda simbólica capaz de gerar valor social e econômico (HEITMAYER, 2025). Heitmayer (2025) distingue a atenção em fluxo, momentânea e transitória, da atenção calcificada, registrada pelas plataformas em métricas como visualizações, curtidas e seguidores. Ao armazenar essas interações, as plataformas transformam a atenção em indicadores mensuráveis, que podem ampliar alcance, influência e potencial de monetização.


2.4 MODELOS DE MACHINE LEARNING

Segundo Gambella et al. (2021), o *Machine Learning* baseia-se no desenvolvimento de modelos capazes de aprender relações intrínsecas aos dados para fornecer respostas adequadas a novas observações. Seu objetivo é permitir que sistemas computacionais utilizem experiências anteriores na resolução de problemas e na realização de previsões em cenários inéditos. Conforme Almuqati et al. (2024), enquanto os modelos supervisionados utilizam dados rotulados para mapear uma função preditiva ou de classificação, os não supervisionados operam sobre dados sem rotulação prévia, buscando identificar padrões, agrupamentos e estruturas ocultas.

3. PROCEDIMENTOS METODOLÓGICOS

Este capítulo apresenta a proposta metodológica adotada para investigar a influência da retenção de vídeos em tela vertical no comportamento de consumo. Foi realizada uma pesquisa de caráter quantitativa, sendo adequada quando o estudo utiliza dados numéricos, mensuração de variáveis e análise estatística de relações entre fenômenos, utilizando a teoria de maneira dedutiva para estudar um fenômeno observado (CRESWELL, 2018).

Figura 1 - Pipeline metodológico



Fonte: Primária (2026)

A figura 1 trata-se de um diagrama para apresentar melhor interpretação e quanto aos procedimentos metodológicos utilizados para realização da pesquisa.

3.1 COLETA DOS DADOS

A pesquisa foi conduzida por meio de um pipeline de dados implementado em Python, documentado em Jupyter Notebook e parametrizado com semente aleatória fixa (`random_state = 42`), garantindo reprodutibilidade integral. Foram utilizadas duas fontes complementares: o Conjunto A, composto por 48 registros reais de vídeos do canal de geologia de Emily Zawacki, exportados via API do TikTok (ZAWACKI, 2022); e o Conjunto B, uma base pública de 48.079 registros de TikTok e YouTube Shorts publicada por Masryo (2025) na plataforma Hugging Face, contendo campos parcialmente estimados conforme declarado pelo autor. O Conjunto A fornece profundidade com métricas auditadas; o Conjunto B permite validação em escala e comparação entre plataformas.

3.2 LIMPEZA E TRATAMENTO DE DADOS

A limpeza foi implementada com a biblioteca *pandas*. Os nomes das colunas foram padronizados por dicionário de renomeação e os valores numéricos convertidos com coerção explícita, transformando entradas inválidas em nulos (NaN) rastreáveis. Para o Conjunto B, as métricas centrais — *engagement_rate* [(likes + comments + shares + saves) / views] e *completion_rate* [avg_watch_time_sec / duration_sec] — foram recalculadas a partir de suas fórmulas constitutivas para auditoria dos valores originais. Em ambos os conjuntos, aplicaram-se filtros de integridade para remoção de registros com valores fisicamente impossíveis, como durações nulas e taxas fora do intervalo [0, 1]. O pipeline foi construído com validações *fail fast*, interrompendo a execução com mensagens descritivas em caso de inconsistência.

3.3 FEATURE ENGINEERING

A partir dos dados limpos, foram derivados atributos que operacionalizam as três dimensões analíticas do estudo. O *engagement_total* foi calculado como soma das interações; o *retention_score* como proporção do vídeo assistida, normalizada para [0, 1]; e o *log_views* como transformação logarítmica das visualizações pela função *log1p* da biblioteca NumPy, para reduzir a assimetria característica de dados de plataformas sociais. A duração foi categorizada em três faixas definidas a priori — muito curto (≤ 15

s), curto-médio (16–60 s) e longo (> 60 s) — por meio de *pd.cut*, com cortes estabelecidos com base na literatura antes da avaliação dos resultados.

3.4 ANÁLISE EXPLORATÓRIA DE DADOS

A análise exploratória utilizou *pandas* e *SciPy*. Estatísticas descritivas completas foram obtidas pelo método *.describe()* e comparadas por plataforma e categoria de duração via *groupby* com agregações nomeadas. As associações entre variáveis foram mensuradas pela correlação de Pearson, reportada com coeficiente (*r*), valor-*p* e marcação de significância: *** $p < 0,001$; ** $p < 0,01$; * $p < 0,05$; ns $p \geq 0,05$. Para o Conjunto B, a análise foi conduzida em três níveis: dataset consolidado, TikTok isolado e YouTube isolado. Essa estratificação verificou se as associações observadas no conjunto combinado se mantêm dentro de cada plataforma, procedimento que identificou um efeito de composição entre plataformas, discutido na seção de resultados.

3.5 VALIDAÇÃO CRUZADA

Para estimar a capacidade de generalização dos modelos, foram adotadas duas estratégias com *scikit-learn*. Para o Conjunto A ($n = 48$), utilizou-se Leave-One-Out Cross Validation (LOOCV), que maximiza os dados de treino ao deixar apenas uma observação como teste em cada iteração. Para o Conjunto B ($n \geq 5.000$), adotou-se 5-fold CV com embaralhamento aleatório e semente fixa. As predições foram obtidas por *cross_val_predict*, gerando para cada observação uma estimativa produzida por um modelo que nunca a viu. O CV R^2 calculado sobre essas predições fora da amostra constitui a métrica de generalização reportada. A lacuna treino-validação ($\text{gap} = R^2_{\text{treino}} - \text{CV } R^2$) foi adotada como diagnóstico de sobreajuste: $\text{gap} \geq 0,30$ indica sobreajuste forte; $\text{gap} \geq 0,15$ exige atenção; $\text{CV } R^2 < 0$ indica ausência de generalização.

3.6 MODELOS DE MACHINE LEARNING

Foram aplicados quatro algoritmos de regressão, a variável-alvo foi a taxa de engajamento e as variáveis preditoras foram duração, retenção relativa e tempo médio absoluto assistido. A Regressão Linear serviu como referência parcimoniosa. A Ridge Regression (HOERL; KENNARD, 1970) foi adotada para mitigar instabilidade por

multicolinearidade, com padronização prévia por StandardScaler. O Random Forest (BREIMAN, 2001) foi incluído por capturar não linearidades e fornecer importância relativa das variáveis (feature_importances). O Gradient Boosting (FRIEDMAN, 2001) complementa o conjunto por modelar padrões aditivos em escala.

A análise foi conduzida em quatro cenários independentes: Conjunto A (n = 48), TikTok público (n = 9.044), YouTube público (n = 5.956) e combinado (n = 15.000), cada um avaliado com a estratégia de validação correspondente ao seu tamanho amostral. Os modelos cumprem papel confirmatório das associações identificadas na análise correlacional, e não de previsão operacional. Para os cenários de machine learning baseados no Conjunto B, utilizou-se uma amostra aleatória de 15.000 registros extraída dos 48.079 originais, com semente fixa (random_state = 42), a fim de reduzir o custo computacional sem comprometer a reprodutibilidade. Dessa amostra derivaram-se os subconjuntos por plataforma (TikTok, n = 9.044; YouTube, n = 5.956), preservando a proporção entre os ecossistemas.

4. ANÁLISE DOS DADOS E DISCUSSÃO DOS RESULTADOS

Os resultados são apresentados em duas frentes metodológicas complementares. O EDA identificou as associações entre variáveis por meio de correlações estatísticas. Os modelos de *Machine Learning* verificaram, por via preditiva independente, se o sinal identificado pelo EDA possui capacidade de generalização em dados não vistos. A convergência entre os dois métodos é o que fundamenta as conclusões do trabalho.

4.1 ANÁLISE EXPLORATÓRIA DE DADOS (EDA)

O resultado da análise exploratória de dados do conjunto de dados A, conforme tabela 1, apresenta o *dataframe* exportado demonstrando as correlações entre retenção e engajamento, com variáveis r, valor-p, significância (ns – sem relevância; * – pouco relevante; ** – relevante; *** – alta relevância) e direção da correlação, demonstrando se há tendência negativa ou positiva.

Tabela 1 – Correlação entre retenção e engajamento


Análise	x	y	r	valor-p	n	Significância	Direção
Duração x retenção relativa	duration	avg_pct_watched	-0,4095	3,8520e-03	48	**	negativa
Duração x engajamento	duration	er_likes	0,3431	1,6971e-02	48	*	positiva
Retenção relativa x engajamento	avg_pct_watched	er_likes	0,2473	9.0186e-02	48	ns	positiva
Watch time absoluto x engajamento	avg_watch_time	er_likes	0.5432	6.6000e-05	48	***	positiva

Fonte: Primária (2026)

A correlação entre duração e retenção relativa resultou em $r = -0,41$ ($p = 0,004$; **): vídeos mais longos tendem a apresentar menor percentual assistido. A correlação entre duração e engajamento foi positiva ($r = 0,34$; $p = 0,017$; *), mas deve ser lida com cautela por ser sensível a extremos. O resultado de maior força foi a correlação entre tempo absoluto assistido e engajamento ($r = 0,54$; $p < 0,001$; ***), enquanto a retenção relativa não atingiu significância ($r = 0,25$; $p = 0,090$; ns). Isso indica que o engajamento é mais fortemente associado ao tempo efetivo de exposição do que à proporção relativa consumida.

No Conjunto B ($n = 48.079$), a correlação entre completion rate e engagement rate foi significativa no dataset consolidado ($r = 0,30$; $p < 0,001$; ***), mas desapareceu ao estratificar por plataforma: TikTok ($r = 0,01$; ns) e YouTube ($r = 0,00$; ns). O TikTok apresenta simultaneamente maior engagement médio (0,092) e maior completion rate (0,676) que o YouTube (0,051 e 0,574), de modo que a mistura das duas plataformas gera uma correlação que não existe dentro de nenhuma delas. A correlação agregada reflete a diferença estrutural entre os ecossistemas, não uma relação interna entre retenção e engajamento.

Figura 2 - Conjunto A aprofundado



Fonte: Primária (2026)


A Figura 2 sintetiza os principais achados do Conjunto A em quatro perspectivas. O histograma de duração concentra-se entre 40 e 65 segundos, com pico próximo a 60 e cauda longa à direita — distribuição assimétrica que justifica a categorização em faixas e a transformação logarítmica. O scatter de duração versus retenção relativa confirma a tendência negativa: vídeos mais curtos concentram os maiores percentuais assistidos. A retenção média por categoria quantifica o padrão — 63,1% nos muito curtos, 47,1% nos intermediários e 36,8% nos longos —, com variabilidade crescente conforme a duração aumenta, indicando que vídeos curtos têm desempenho mais previsível. Já o scatter de retenção versus engajamento mostra tendência positiva com ampla dispersão, consistente com a correlação $r = 0,25$ não significativa: há uma direção, mas sem força estatística suficiente para $n = 48$.

4.2 MODELOS DE MACHINE LEARNING

A análise de importância de variáveis pelo Random Forest, ilustrada na Figura 3, reforça os achados correlacionais sob uma perspectiva algorítmica independente. No Conjunto A, o tempo absoluto assistido (`avg_watch_time`) concentrou aproximadamente 65% da

importância preditiva, contra 22% da retenção relativa e 13% da duração — hierarquia diretamente consistente com os coeficientes de Pearson obtidos na EDA ($r = 0,54$ para watch time, $r = 0,25$ ns para retenção relativa). Nos cenários públicos por plataforma, a importância se redistribuiu de forma equilibrada entre as variáveis disponíveis, sem dominância clara, o que é coerente com a ausência de correlação interna detectada.

Figura 3 - Importância de features



Fonte: Primária (2026)

Conforme figura 3, no cenário combinado a `completion_rate` assumiu aproximadamente 65% da importância — comportamento esperado dado o efeito de composição: o modelo utilizou essa variável como proxy da diferença estrutural entre TikTok e YouTube, e não como preditor de engajamento dentro de cada ecossistema. A convergência entre a hierarquia de importâncias do Random Forest e os resultados da análise correlacional constitui a principal evidência de consistência metodológica do trabalho: dois métodos distintos, aplicados sobre os mesmos dados, produziram as mesmas conclusões.

Nos cenários por plataforma isolada, todos os modelos apresentaram CV R^2 próximo de zero ou negativo, confirmando por via preditiva a ausência de correlação

interna identificada pelo EDA. No cenário combinado, o Gradient Boosting alcançou $CV R^2 = 0,17$ (gap = 0,01), mas o diagnóstico de confundimento revelou que apenas a identidade da plataforma já explica 44,5% da variação, sem ganho ao adicionar as métricas de retenção ($CV R^2 = 0,4448$ vs. 0,4445). O sinal do cenário combinado é, portanto, produto da diferença entre TikTok e YouTube, não do efeito das métricas de conteúdo. A convergência entre EDA e ML é o principal achado metodológico: dois métodos distintos identificaram, de forma independente, que o tempo absoluto assistido é a variável mais associada ao engajamento no canal real, que essa relação some dentro de cada plataforma e que o padrão agregado decorre da composição entre ecossistemas. Percursos distintos, mesmas conclusões — o que fortalece a confiança nos achados dentro das limitações observacionais do estudo.

5. CONCLUSÃO

O avanço das plataformas digitais e a consolidação dos vídeos verticais como linguagem nativa do ambiente mobile colocaram a atenção do usuário no centro das estratégias de marketing digital. Diante desse contexto, este trabalho buscou responder à seguinte questão: como a retenção de atenção em conteúdos de tela vertical influencia o comportamento de consumo? O objetivo foi analisar essa influência nas plataformas TikTok e YouTube Shorts, por meio de técnicas de análise de dados e aprendizado de máquina.

Os resultados sugerem que a retenção influencia o engajamento, mas não de forma uniforme. No estudo de caso com dados reais, o tempo absoluto assistido apresentou a associação mais forte com o engajamento ($r = 0,54$; $p < 0,001$), enquanto a retenção relativa não atingiu significância estatística ($r = 0,25$; ns). Os modelos de aprendizado de máquina confirmaram essa hierarquia de forma independente, com o tempo absoluto concentrando cerca de 65% da importância preditiva no Random Forest. A convergência entre EDA e ML é o que fundamenta essa conclusão. No conjunto público em escala, a correlação aparente entre retenção e engajamento desaparecia ao separar as plataformas, revelando um caso do paradoxo de Simpson: o sinal refletia a diferença estrutural entre TikTok e YouTube, e não uma relação interna a cada

ecossistema. Esses achados indicam que cada plataforma deve ser analisada de forma independente, e que interpretações agregadas podem ser enganosas.

É importante ressaltar que os dados disponíveis medem engajamento, e não decisões de consumo diretamente. A influência sobre o comportamento de consumo, portanto, é inferida a partir do engajamento como indicador de interesse, e não comprovada de forma direta — o que representa uma limitação observacional do estudo. Para trabalhos futuros, sugere-se a utilização de datasets de maior volume com dados reais e auditados de múltiplos canais e plataformas, incluindo o Instagram Reels, bem como a incorporação de dados de conversão que permitam investigar diretamente a relação entre engajamento e comportamento de consumo.

REFERÊNCIAS

ALMUQATI, Mohammed Tuays et al. Challenges in Supervised and Unsupervised Learning: A Comprehensive Overview. **International Journal on Advanced Science, Engineering and Information Technology**, [S. l.], v. 14, n. 4, p. 1449-1455, 2024. Disponível em: <https://ijaseit.insightsociety.org/index.php/ijaseit/article/view/20191>. Acesso em: 27 maio 2026.

BREIMAN, Leo. Random forests. **Machine Learning**, [S. l.], v. 45, n. 1, p. 5-32, out. 2001. DOI: <https://doi.org/10.1023/A:1010933404324>. Disponível em: <https://link.springer.com/article/10.1023/A:1010933404324>. Acesso em: 27 maio 2026.

CRESWELL, John W.; CRESWELL, J. David. **Research design: qualitative, quantitative, and mixed methods approaches**. 5. ed. Los Angeles: SAGE, 2018. Disponível em: <https://zenodo.org/records/19616730>. Acesso em: 15 mar. 2026.

DAVENPORT, Thomas H.; BECK, John C. **The attention economy: understanding the new currency of business**. Boston: Harvard Business School Press, 2001. 255 p. ISBN 978-1578514410. Disponível em: https://books.google.com.br/books?id=j6z-MiUKgosC&redir_esc=y. Acesso em: 10 jan. 2026.

FRIEDMAN, Jerome H. Greedy function approximation: a gradient boosting machine. **The Annals of Statistics**, [S. l.], v. 29, n. 5, p. 1189-1232, out. 2001. DOI: <https://doi.org/10.1214/aos/1013203451>. Disponível em: <https://projecteuclid.org/journals/annals-of-statistics/volume-29/issue-5/Greedy-function-approximation-A-gradient-boosting-machine/10.1214/aos/1013203451.full>. Acesso em: 22 maio 2026.

GAMBELLA, Claudio; GHADDAR, Bissan; NAOUM-SAWAYA, Joe. Optimization problems for machine learning: A survey. **European Journal of Operational Research**, [S. l.], v. 290, n. 3, p. 807-828, 2021. DOI: <https://doi.org/10.1016/j.ejor.2020.08.045>. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S037722172030758X>. Acesso em: 27 maio 2026.

HEITMAYER, Maxi. The Second Wave of Attention Economics: Attention as a Universal Symbolic Currency on Social Media and beyond. **Interacting with Computers**, [S. l.], v. 37, n. 1, p. 18-29, 2025. DOI: <https://doi.org/10.1093/iwc/iwae035>. Disponível em: <https://academic.oup.com/iwc/article/37/1/18/7733851>. Acesso em: 10 fev. 2026.

HOERL, Arthur E.; KENNARD, Robert W. Ridge regression: biased estimation for nonorthogonal problems. **Technometrics**, [S. l.], v. 12, n. 1, p. 55-67, fev. 1970. DOI: <https://doi.org/10.1080/00401706.1970.10488634>. Acesso em: 27 maio 2026.

MANIC, Marius. Short-form video content and consumer engagement in digital landscapes. **Bulletin of the Transilvania University of Braşov, Series V: Economic**

Sciences, Braşov, v. 17, n. 66, n. 1, p. 45-52, 2024. DOI: <https://doi.org/10.31926/but.es.2024.17.66.1.4>. Disponível em: https://webbut.unitbv.ro/index.php/Series_V/article/view/7965. Acesso em: 27 maio 2026.

MASRYO, Tarek. **YouTube Shorts & TikTok Trends (2025)**. [S. l.]: Hugging Face Datasets, 2025. Disponível em: <https://huggingface.co/datasets/tarekmasryo/youtube-tiktok-trends-dataset-2025>. Acesso em: 10 jan. 2026.

MULIER, Lana; SLABBINCK, Hendrik; VERMEIR, Iris. This Way Up: The Effectiveness of Mobile Vertical Video Marketing. **Journal of Interactive Marketing**, [S. l.], v. 55, p. 1-15, 2021. DOI: <https://doi.org/10.1016/j.intmar.2020.12.002>. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1094996820301420>. Acesso em: 10 fev. 2026.

NAVARRO-GÜERE, Héctor. Vertical video. A review of the literature on communication. **Revista Mediterránea de Comunicación**, [S. l.], v. 14, n. 1, p. 69-81, 2023. DOI: <https://doi.org/10.14198/MEDCOM.23028>. Disponível em: <https://www.mediterranea-comunicacion.org/article/view/23028>. Acesso em: 10 fev. 2026.

SCIENTIA MOBILE. **MOVR Mobile Overview Report October–December 2014**. [S. l.]: ScientiaMobile, 2014. Disponível em: <https://scientiamobile.com/movr-mobile-overview-report/>. Acesso em: 15 mar. 2026.

SIMON, Herbert A. Designing organizations for an information-rich world. In: GREENBERGER, Martin (ed.). **Computers, communications, and the public interest**. Baltimore: The Johns Hopkins Press, 1971. p. 37-72. Disponível em: <https://gwern.net/doc/design/1971-simon.pdf>. Acesso em: 20 maio 2026.

SIMPSON, Edward H. The interpretation of interaction in contingency tables. **Journal of the Royal Statistical Society: Series B (Methodological)**, [S. l.], v. 13, n. 2, p. 238-241, 1951. DOI: <https://doi.org/10.1111/j.2517-6161.1951.tb00088.x>. Disponível em: <https://academic.oup.com/jrsssb/article/13/2/238/70026675>. Acesso em: 27 maio 2026.

VALEZA, Jeric M.; SORIANO, Maria Jamaica C. The influence of TikTok short-form videos on Gen Z consumers' purchase intention. **International Journal of Multidisciplinary Academic Research**, [S. l.], v. 12, n. 1, p. 38-53, 2024. Disponível em: <https://www.semanticscholar.org/paper/THE-INFLUENCE-OF-TIKTOK-SHORT-FORM-VIDEOS-ON-GEN-Z-Valeza-Jamaica/aa5487709ed4b3da20bddd5b304c748e36ab180>. Acesso em: 10 fev. 2026.

VERGARA, Sylvia Constant. **Projetos e relatórios de pesquisa em administração**. São Paulo: Atlas, 2004. Disponível em: <https://scholar.google.com>. Acesso em: 15 mar. 2026.

YANG, Shentao; YANG, Haichuan; DU, Linna; GANESH, Adithya; PENG, Bo; LIU, Boying; LI, Serena; LIU, Ji. SWaT: Statistical modeling of video watch time through user behavior analysis. In: ACM SIGKDD CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 31., 2025, Toronto. **Proceedings** [...]. New York: Association for Computing Machinery, 2025. p. 2768-2778. DOI: <https://doi.org/10.1145/3690624.3709415>. Disponível em: <https://arxiv.org/abs/2408.07759>. Acesso em: 27 maio 2026.

ZAWACKI, E. E. et al. Exploring TikTok as a promising platform for geoscience communication. **Geoscience Communication**, [S. l.], v. 5, p. 363-380, 2022. DOI: <https://doi.org/10.5194/gc-5-363-2022>. Disponível em: <https://doi.org/10.5194/gc-5-363-2022>. Acesso em: 20 jun. 2025.